

Paralelização do ACO com CUDA e OpenMP para Seleção de Instâncias em Larga Escala

Raphael A. L. Soares¹, Wagner Victor A. Menezes¹,
Victor Gabriel R. Jácome¹, Daniel Rios Borges¹

¹Instituto de Informática – Universidade Federal de Goiás (UFG)
Caixa Postal 131 – CEP 74001-970 – Goiânia - GO – Brasil

{raphael.alves, wagnervictor, victor.ribeiro, daniel.rios}@discente.ufg.br

Abstract. *Instance selection reduces dataset size while preserving classifier quality, but Ant Colony Optimization (ACO), although effective, has an $O(N^2)$ cost that makes it infeasible at large scale: the sequential C++ baseline of Magalhães et al. (2024) does not scale to large bases. We parallelize ACO-based instance selection in OpenMP (CPU) and CUDA (GPU), running the 1-NN evaluation entirely on the GPU, and assess the impact of thread count, scheduler and block size. On nine datasets ($\leq 5k$ instances) a 24-core OpenMP run beats the GPU, but on a 253,680-instance base CUDA reaches $\sim 69\times$ over the sequential version (vs. $\sim 14\times$ for OpenMP), keeping the same quality ($\sim 23\%$ reduction, $F_1 \approx 0.77$). The GPU advantage is therefore scale-dependent: it dominates once the problem is large enough to amortize its overhead.*

Resumo. *A seleção de instâncias reduz o tamanho de bases de dados preservando a qualidade de classificadores, mas a Otimização por Colônia de Formigas (ACO), embora eficaz, tem custo $O(N^2)$ que a inviabiliza em larga escala: o baseline sequencial em C++ de Magalhães et al. (2024) não escala para grandes bases. Este trabalho paraleliza o ACO de seleção de instâncias em OpenMP (CPU) e CUDA (GPU), com a avaliação 1-NN inteiramente na GPU, e mede o impacto de threads, escalonadores e tamanho de bloco. Em nove bases ($\leq 5k$ instâncias) o OpenMP em 24 núcleos supera a GPU, mas em uma base de 253.680 instâncias o CUDA atinge $\sim 69\times$ sobre o sequencial (contra $\sim 14\times$ do OpenMP), preservando a qualidade ($\sim 23\%$ de redução, $F_1 \approx 0,77$). Conclui-se que o ganho da GPU é dependente de escala: ela domina quando o problema é grande o suficiente para amortizar seu custo fixo.*

1. Introdução

Modelos de aprendizado de máquina dependem de conjuntos de treinamento representativos, e bases reais frequentemente contêm instâncias redundantes ou ruidosas que aumentam o custo computacional sem agregar informação. A *seleção de instâncias* ataca esse problema: busca um subconjunto compacto dos dados que preserve (ou melhore) a acurácia de um classificador, reduzindo tempo e recursos de treinamento [Olvera-López et al. 2010].

A Otimização por Colônia de Formigas (ACO) [Dorigo et al. 2006] é uma metaheurística bioinspirada eficaz para seleção de instâncias quando usada

como método *wrapper*, guiando a escolha de instâncias por um classificador 1-NN [Cover and Hart 1967]. Sua principal limitação é o custo computacional: tanto o cálculo de distâncias quanto a avaliação 1-NN são $O(N^2)$ no número de instâncias N , o que torna o algoritmo caro à medida que a base cresce.

O baseline deste trabalho, Magalhães et al. [Magalhães et al. 2024], reescreveu o ACO de Python para C++ e obteve ganhos expressivos de desempenho mantendo a qualidade. Entretanto, essa versão permanece **sequencial**, e os próprios autores apontam que o alto custo computacional “limita sua escalabilidade, tornando-o inviável para grandes bases de dados”. Existe, portanto, uma lacuna clara: falta uma versão **paralela** do ACO de seleção de instâncias capaz de explorar CPUs multicore e GPUs para viabilizar o algoritmo em larga escala.

A paralelização do ACO é um tema bem estabelecido [Pedemonte et al. 2011], com implementações eficientes em CPU multicore via OpenMP [Abouelfarag et al. 2015] e em GPU via CUDA [Delévacq et al. 2013] que alcançam acelerações de uma a duas ordens de grandeza. Esses trabalhos, contudo, concentram-se em problemas de roteamento — sobretudo o caixeiro-viajante — nos quais o gargalo é a *construção de caminhos*. Na seleção de instâncias o gargalo é distinto: a avaliação 1-NN $O(N^2)$, uma carga *memory-bound* [Williams et al. 2009]. Não encontramos na literatura uma avaliação sistemática da paralelização (OpenMP e CUDA) do ACO de seleção de instâncias em larga escala.

Implementamos o ACO de seleção de instâncias em OpenMP (CPU) [Dagum and Menon 1998] e CUDA (GPU) [Nickolls et al. 2008], movendo a avaliação 1-NN inteiramente para a GPU, e avaliamos o impacto do número de threads, do escalonador de laço e do tamanho de bloco. Nas nove bases pequenas ($\leq 5k$ instâncias) o OpenMP em 24 núcleos supera a GPU, cujo custo fixo não se amortiza; já na base CDC Diabetes de 253.680 instâncias o CUDA atinge $\sim 69\times$ de aceleração sobre o sequencial (contra $\sim 14\times$ do OpenMP), preservando a qualidade da solução ($\sim 23\%$ de redução com $F_1 \approx 0,77$). O resultado central é que *o ganho da GPU é dependente de escala*.

2. Formulação do Problema

Seja um conjunto $X = \{x_1, \dots, x_N\}$ com N instâncias e F atributos. A seleção de instâncias procura um subconjunto $S \subseteq X$ que minimize $|S|$ mantendo a acurácia de um classificador treinado em S . No ACO, cada uma de K formigas constrói uma solução binária (seleciona ou não cada instância) guiada por dois fatores: o *feromônio* τ_i , que acumula a utilidade histórica de incluir a instância i , e a *visibilidade* η_i , derivada da distância média da instância às demais. A probabilidade de seleção é proporcional a $\tau_i^\alpha \eta_i^\beta$. A qualidade de cada solução é medida por um classificador 1-NN aplicado sobre o subconjunto selecionado, e o feromônio é reforçado nas soluções de maior F_1 e evaporado a cada iteração.

O custo computacional concentra-se em dois pontos $O(N^2F)$: o pré-cálculo de distâncias e, sobretudo, a avaliação 1-NN, na qual cada instância de teste busca seu vizinho mais próximo no subconjunto selecionado. Para $N = 253,680$, isso significa da ordem de 10^{10} comparações por iteração — o gargalo que motiva a paralelização.

3. Objetivos

1. Implementar o ACO de seleção de instâncias em três versões — sequencial (baseline), OpenMP (CPU) e CUDA (GPU) — com qualidade equivalente.
2. Superar o baseline sequencial em desempenho, preservando a qualidade da seleção (medida por F_1 e taxa de redução).
3. Avaliar a escalabilidade: em OpenMP, variando o número de threads e o escalonador de laço; em CUDA, variando o tamanho de bloco.
4. Reportar o *speedup* (absoluto e relativo) em bases de tamanhos distintos, incluindo uma base de larga escala (253.680 instâncias).

4. Metodologia

4.1. Algoritmo e implementações

As três versões compartilham o mesmo ACO de seleção guiada por feromônio ($\alpha = \beta = 1$, taxa de evaporação 0,1, $K = 64$ formigas). A construção de soluções é *embarçosamente paralela*: cada formiga escreve apenas em sua fatia da colônia e lê o vetor de probabilidades como dado somente-leitura, com gerador aleatório semeado por (*iteração*, k) para garantir determinismo independente do paralelismo.

Na versão **OpenMP**, paralelizam-se a construção das formigas, o depósito de feromônio (com `atomic` para evitar condições de corrida) e, principalmente, a avaliação 1-NN — o laço quente, que responde por mais de 98% do tempo. Esse laço usa `schedule(runtime)`, permitindo controlar o escalonador via a variável `OMP_SCHEDULE`. Na versão **CUDA**, a avaliação 1-NN roda inteiramente na GPU (`knn_1nn_kernel`: uma thread por instância de teste), eliminando o transporte da colônia $K \times N$ a cada iteração; para N grande, o feromônio é mantido como vetor 1D e as distâncias são calculadas *on-the-fly*, evitando a matriz $N \times N$.

4.2. Configuração experimental

Todos os experimentos rodaram na **mesma máquina**: Intel Core i9-14900K (24 núcleos físicos — 8 *performance* + 16 *efficiency* — e 32 threads) e GPU NVIDIA GeForce RTX 4090 (24 GB). Avaliamos nove bases do baseline (de 299 a 4.981 instâncias) e a base **CDC Diabetes Health Indicators** [Centers for Disease Control and Prevention 2015] (253.680 instâncias, 21 atributos). Para a comparação dos nove datasets, fixamos 100 iterações em todos os modos, garantindo comparação justa de tempo. No experimento de larga escala (CDC) habilitamos *early stopping* (parada após 20 iterações sem melhora). As métricas são F_1 , taxa de redução, tempo de execução, vazão (GFLOPS) e *speedup*. Para o CDC, o *speedup* é normalizado por iteração, usando como referência (T_1) uma execução de 1 thread da mesma campanha. O código e os dados estão disponíveis publicamente¹.

5. Resultados

5.1. Escala pequena/média: a CPU multicore supera a GPU

A Figura 1 e a Tabela 1 mostram o desempenho nas nove bases. A qualidade é preservada por todas as implementações (variações de F_1 entre seq, OpenMP e CUDA ficam dentro

¹<https://github.com/phael-exe/aco-selection-parallel>

de $\sim 2\%$, ruído estatístico do algoritmo estocástico), com redução de 6% a 22% das instâncias. Quanto ao tempo, o *speedup* da CUDA cresce com N (de $0,7\times$ na menor base a $8,2\times$ na maior), mas em **todas** as nove bases o OpenMP em 24 núcleos é mais rápido que a GPU: o custo fixo de lançamento de kernels e de transferência host–device não se amortiza enquanto o problema é pequeno. Em bases de poucos milhares de instâncias, portanto, a CPU multicore é a melhor escolha.




Figura 1. O ganho da GPU cresce com o tamanho da base, mas até $\sim 5k$ instâncias o OpenMP em 24 núcleos supera a CUDA: o custo fixo da GPU só se amortiza em escala maior.

Tabela 1. Qualidade e *speedup* nas nove bases (100 iterações, sequencial como referência). F_1 do sequencial; melhor configuração OpenMP entre threads e escalonadores.

Dataset	N	F_1	Red. (%)	CUDA	OpenMP (melhor)
heart_failure	299	0,887	19,4	$0,7\times$	$2,9\times$
haberman	306	0,881	19,9	$1,8\times$	$3,6\times$
cirrhosis	418	0,867	21,5	$0,9\times$	$4,0\times$
diabetes	768	0,906	19,5	$1,5\times$	$4,5\times$
tic-tac-toe	958	0,979	6,7	$1,8\times$	$5,8\times$
yeast	1484	0,979	6,3	$2,4\times$	$6,5\times$
vaccine	3152	0,958	12,7	$5,9\times$	$13,0\times$
Employee	4653	0,809	22,2	$7,4\times$	$10,4\times$
brain-stroke	4981	0,727	22,4	$8,2\times$	$11,5\times$

5.2. Escalonadores OpenMP: *dynamic* vence *static*

A avaliação 1-NN é uma carga *irregular* (instâncias com vizinhos próximos terminam mais cedo), o que favorece escalonadores que rebalanceiam a carga. A Figura 2 compara, com 16 threads, os escalonadores *static* (partição em blocos) e *dynamic* (distribuição sob demanda) e seus tamanhos de *chunk*. Nas bases maiores, o *dynamic* é em média $\sim 25\text{--}30\%$ mais rápido que o *static*, enquanto o tamanho de *chunk* (1, 2 ou 3) tem efeito secundário. O balanceamento dinâmico compensa porque cada iteração do laço

quente é pesada o suficiente para diluir o custo da fila compartilhada. O resultado está alinhado a estudos anteriores de *tuning* de escalonadores e de número de threads em ACO paralelo [Abouelfarag et al. 2015].




Figura 2. Tempo relativo ao `static` (16 threads, média geométrica das bases ≥ 1000 instâncias): o `dynamic` reduz o tempo em $\sim 25\text{--}30\%$; o tamanho de *chunk* é secundário.

5.3. Larga escala (253.680 instâncias): a GPU domina

Na base CDC, o quadro se inverte. A Tabela 2 resume o desempenho. O OpenMP escala bem com o número de threads, chegando a $\sim 14\times$ (`static`) e $\sim 16\times$ (`dynamic`) sobre 1 thread ao usar as 32 threads do i9-14900K, confirmando que o `dynamic` mantém vantagem em escala. A CUDA, por sua vez, atinge **38–69** $\times$ sobre o sequencial, executando a campanha completa em cerca de 2 minutos. A melhor configuração CUDA é $\sim 4,3\times$ mais rápida que a melhor configuração OpenMP (32 threads).

Tabela 2. Desempenho na base CDC (253.680 instâncias; *early stopping* em 22 iterações; *speedup* normalizado por iteração vs. 1 thread). Qualidade idêntica entre os modos.

Modo	Configuração	Tempo	Speedup
OpenMP	2 threads (static)	109,2 min	1,3 $\times$
OpenMP	32 threads (static)	9,7 min	14,0 $\times$
OpenMP	32 threads (dynamic)	8,6 min	15,9 $\times$
CUDA	block size 64	151 s	54,0 $\times$
CUDA	block size 1024	118 s	69,1$\times$

A varredura de tamanho de bloco da CUDA (Figura 3) revela uma curva em U: os extremos (bloco 32 e 1024) são mais rápidos e o meio (64–128) mais lento, com diferença de $\sim 28\%$ entre o melhor e o pior. A explicação está no padrão de acesso do `knn_lnn_kernel`: todas as threads leem a mesma linha de referência simultaneamente, em *broadcast*. Blocos grandes maximizam o reuso desse *broadcast*, favorecidos pela coalescência de memória [NVIDIA Corporation 2024]; blocos pequenos, embora de menor ocupância, mantêm o desempenho — pois ocupância alta não implica melhor desempenho quando há paralelismo de instruções e de memória suficiente [Volkov 2010];

o meio perde nos dois efeitos. O padrão é reprodutível (variação $<0,2\%$ entre execuções repetidas), confirmando que não é ruído.




Figura 3. CUDA na base CDC: a curva de tempo e vazão por tamanho de bloco tem forma de U — os extremos vencem por equilibrarem reuso de *broadcast* e ocupância dos SMs.

Em todos os modos a solução converge para a mesma qualidade: $\sim 23\%$ de redução de instâncias mantendo $F_1 \approx 0,77$ — a paralelização altera o tempo, não o resultado. O *early stopping* reduziu cada execução para 22 iterações, economizando $\sim 78\%$ do tempo sem perda de qualidade.

6. Conclusão

Este trabalho paralelizou o ACO de seleção de instâncias em OpenMP e CUDA, preenchendo a lacuna de escalabilidade deixada pelo baseline sequencial de Magalhães et al. [Magalhães et al. 2024] e viabilizando o algoritmo em uma base de 253.680 instâncias. O resultado central é que **o ganho da GPU é dependente de escala**: em bases de até $\sim 5k$ instâncias, o custo fixo da GPU não se amortiza e o OpenMP em 24 núcleos é mais rápido; em larga escala, a CUDA domina, atingindo $\sim 69\times$ sobre o sequencial e sendo $\sim 4,3\times$ mais rápida que a melhor configuração de CPU. Em todos os casos, a qualidade da seleção é preservada ($\sim 23\%$ de redução, $F_1 \approx 0,77$).

As principais limitações são o uso de uma única base de larga escala e a ausência de *profiling* de hardware (ocupância, vazão de memória) para confirmar quantitativamente a explicação da curva em U. Como trabalhos futuros, pretende-se investigar a *co-execução híbrida* CPU+GPU — particionando o trabalho entre os dispositivos — e estender a avaliação a mais bases de larga escala, aproximando ainda mais o algoritmo de aplicações reais de mineração de dados.

Referências

Abouelfarag, A. A., Mohamed Aly, W., and Elbially, A. G. (2015). Performance analysis and tuning for parallelization of ant colony optimization by using OpenMP. In *Computer Information Systems and Industrial Management (CISIM)*, volume 9339 of *LNCS*, pages 73–85. Springer.

- Centers for Disease Control and Prevention (2015). CDC diabetes health indicators dataset (BRFSS 2015). UCI Machine Learning Repository. 253.680 instâncias, 21 atributos.
- Cover, T. M. and Hart, P. E. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1):21–27.
- Dagum, L. and Menon, R. (1998). OpenMP: An industry standard API for shared-memory programming. *IEEE Computational Science and Engineering*, 5(1):46–55.
- Delévacq, A., Delisle, P., Gravel, M., and Krajecki, M. (2013). Parallel ant colony optimization on graphics processing units. *Journal of Parallel and Distributed Computing*, 73(1):52–61.
- Dorigo, M., Birattari, M., and Stützle, T. (2006). Ant colony optimization. *IEEE Computational Intelligence Magazine*, 1(4):28–39.
- Magalhães, J. M. d. O., Gonçalves, A. C. M., Nobre, C. N., and Freitas, H. C. d. (2024). Avaliação de desempenho e escalabilidade do algoritmo de otimização de colônia de formigas em C++ e Python. Código disponível em: <https://github.com/jmarcosjm/aco-cpp>.
- Nickolls, J., Buck, I., Garland, M., and Skadron, K. (2008). Scalable parallel programming with CUDA. *ACM Queue*, 6(2):40–53.
- NVIDIA Corporation (2024). CUDA C++ best practices guide. <https://docs.nvidia.com/cuda/cuda-c-best-practices-guide/>.
- Olvera-López, J. A., Carrasco-Ochoa, J. A., Martínez-Trinidad, J. F., and Kittler, J. (2010). A review of instance selection methods. *Artificial Intelligence Review*, 34(2):133–143.
- Pedemonte, M., Nesmachnow, S., and Cancela, H. (2011). A survey on parallel ant colony optimization. *Applied Soft Computing*, 11(8):5181–5197.
- Volkov, V. (2010). Better performance at lower occupancy. In *GPU Technology Conference (GTC)*. NVIDIA. University of California, Berkeley.
- Williams, S., Waterman, A., and Patterson, D. (2009). Roofline: An insightful visual performance model for multicore architectures. *Communications of the ACM*, 52(4):65–76.